

DOSSIER DE CANDIDATURE EN DOCTORAT

Consignes :

**Remplir l'ensemble des fiches ci-après
Retourner le dossier complet à l'ED MSTIC
(De façon centralisée par votre laboratoire)**

- Formulaire de candidature complété et signé par le candidat, le directeur de thèse et le directeur de laboratoire,
- CV détaillé,
- Notes de M1 et M2 avec le classement et les effectifs si possible

Contact : ed-mstic@univ-eiffel.fr

DOSSIER DE CANDIDATURE AU DOCTORAT

ANNÉE 2026/2027

FICHE CANDIDAT

Nom : CHAU

Prénom : Dang Minh

Sexe : F ☐ - M ☒

Adresse : 5 Av. du Pavé Neuf

Code postal : 93160

Ville : Noisy-le-Grand



Pays: France

Date et lieu de naissance - né(e) le : 22/08/2002 - Vietnam Nationalité :

vietnamien

à (ville) : Vinh Long

- (Pays) : Vietnam

E-mail : 1- dang-minh.chau@edu.univ-eiffel.fr - 2 - dangminh2208@gmail.com

FORMATIONS ANTÉRIEURES

(Indiquez les diplômes [y compris le baccalauréat], les établissements et les années d'obtention)

	Diplôme	Année	Etablissement - Ville	Pays
1	M.Sc - Mathématiques et Applications	2025	Université de Limoges - Limoges	France
2	B.Eng - Informatique	2024	University of Technology (VNU-HCM) - Ho Chi Minh City	Vietnam

3	Baccalauréat	2020	Nguyen Binh Khiem High School for the Gifted - Vinh Long	Vietnam
4				
5				

Le DOCTORAT EN PRÉPARATION

SPÉCIALITÉ

1 seul choix :

☐	Electronique, Optronique et Systèmes
☐	Informatique
☐	Mathématiques
☐	Sciences et Technologies de l'Information Géographique
☐	Signal, Image, Automatique

ENCADREMENT DE THESE

- **Sujet de la thèse :** *(décrire ici en quelques lignes) analyse mathématique réaliste d'algorithmes modernes, qui utilisent les instructions SIMD pour de meilleures performances.*

- **Direction de thèse** (Nom/prénom) : NICAUD Cyril

E-mail : cyril.nicaud@univ-eiffel.fr

Nombre de thèses encadrées **actuellement** : aucune

Autres chercheurs participant à l'encadrement des travaux :

P dans le laboratoire (nom/prénom) : ROTONDO Pablo

P à l'extérieur du laboratoire (nom/prénom/laboratoire) :

- **Laboratoire d'accueil :**

A préciser (nom/équipe/ UMR, EA...) : LIGM,

Equipe BAAM, UMR 8049

Adresse : 5 bd Descarte 77454 Champs-sur-Marne

- **Etablissement d'inscription du**

doctorant :

☐ UGE

☐ UPEC

THÈSE EN COTUTELLE

Attention ! La convention de cotutelle devra être signée durant la 1^{ère} année de thèse

Non ☐ Oui ☐ - Avec quel pays :

Si oui : Paiement des frais de scolarité : ☐ En France ☐ Dans le pays de la cotutelle

Le PROJET DE RECHERCHE

Context: A thorough examination of the algorithms implemented in the standard libraries of modern programming languages reveals significant deviations from the traditional textbook algorithms [1]. Even with classical data structures and algorithms, such as hash tables or sorting methods, a closer look at the source code shows that engineers often diverge from the expected paths, creating new algorithms or combining existing techniques in innovative ways.

New algorithms and heuristics are continuously being developed in contemporary programming languages. Critical algorithms and data structures for each language undergo constant refinement, modification, or even complete redesign. Unlike academic dissemination, these developments are primarily shared through collaborative development platforms, mailing lists, and developer conferences. Despite the open availability of source code, the benchmarks and methodologies that inform the choice of a particular implementation are often missing or hard to find.

An emblematic example is the sorting algorithm TimSort, designed by the PYTHON's engineer Tim Peters in the early 2000's, which progressively gained popularity and which is now used in Java, Javascript, etc. Its story has been eventful, and the final version of TimSort, its formal proof of correctness, and its complexity were established with the decisive help of academic researchers [2]. Importantly, TimSort remained unnoticed by the academic community for more than 10 years despite being widely used in real world. Eventually, the techniques and metrics used for the theoretical study of TimSort led the academic community to propose new sorting algorithms, including the PowerSort algorithm [3], which was recently adopted by PYTHON.

Other attempts by the academic community to study algorithms and data structures as they are used in practice, such as the double-pivot QuickSort in Java [4] or the hybrid hash tables in LUA [5], reveal two primary motivations for deviating from textbook algorithms. The first is to leverage the features of modern computer architectures, such as vectorized instructions (SIMD). The second is to optimize the algorithm's performance for real-world data. For example, the TimSort algorithm was specifically designed to exploit the fact that, in many practical scenarios, arrays often contain large, pre-sorted segments, allowing it to perform sorting operations more efficiently.

Although reliable statistics on this topic are scarce, it is reasonable to assume that the vast majority of real-world implementations of common data structures and algorithms originate from the standard libraries of fewer than 25 programming languages, with most coming from a core group of fewer than 5. Therefore, any improvement to these key implementations should be fully understood, as it could have a substantial impact on real-world applications.

Main objectives of the PhD: the main objective consists in providing mathematical insight into real-world implementations of standard algorithms and heuristics based on SIMD instructions. Beyond conducting detailed studies of key implementations, the primary goal is to develop a comprehensive theoretical framework for analyzing modern algorithms and data structures, which could be used to guide the evolutions of these algorithms. Additionally, we aim to create mathematical models that capture the key statistical properties of real-world data and validate these models against state-of-the-art implementations.

Roadmap: we propose the following steps, to be adapted depending on the results we are able to obtain.

1. Perform a detailed fine-grain analysis of Usenix HYPERSCAN algorithm (<https://www.usenix.org/system/files/nsdi19-wang-xiang.pdf>), which massively uses SIMD instruction, among other classical techniques, for matching of regular expressions. There are many challenges in carrying out the analysis successfully, across almost every aspect of the thesis: computer architecture, modelling of typical data, and mathematical analysis.
2. Identify other implementations relying on SIMD instructions and conduct a detailed analysis. There are many candidates, so the task will be to sort those whose study presents a methodological interest from those that fall under one-off optimisation.
3. Build a relevant theoretical methodological framework for adding SIMD instructions to an abstract computer model. Develop the necessary mathematical tools to conduct algorithm analyses within this model.
4. Use the model and analysis tools to design new efficient algorithms that fully exploit the capabilities offered by SIMD instructions.
5. Implement the new algorithms and compare the proposed solutions against the state of the art, using the benchmarks commonly employed in the field.

[1] D. E. Knuth. *The Art of Computer Programming: Sorting and Searching*, volume 3. Addison-Wesley, 2nd edition, 1998.

[2] N. Auger, V. Jugé, C. Nicaud, and C. Pivoteau. *On the Worst-Case Complexity of TimSort*. In 26th Annual European Symposium on Algorithms (ESA 2018). LIPICs, 2018.

[3] J. I. Munro and S. Wild. *Nearly-optimal mergesorts: Fast, practical sorting methods that optimally adapt to existing runs*. In 26th Annual European Symposium on Algorithms (ESA 2018), LIPICs, 2018.

[4] C. Martinez, M. E. Nebel, and S. Wild. *Analysis of branch misses in QuickSort*. In 2015 Proceedings of the Twelfth Workshop on Analytic Algorithmics and Combinatorics (ANALCO 2015), pages 114–128. SIAM, 2015.

[5] C. Martinez, C. Nicaud, and P. Rotondo. *Mathematical models to analyze Lua hybrid tables*. Theoretical Computer Science 1044 (2025)

AVIS DU DIRECTEUR DE THÈSE

Sur le programme de recherche ci-dessus

(Aptitudes du candidat, intérêt du sujet, plan de travail...)

Avis (½ page) :

Le sujet de thèse s'inscrit dans une direction de recherche à laquelle participent 7 enseignant-chercheurs du LIGM. La thématique précise des instructions SIMD est particulièrement intéressante, de nombreuses nouvelles implantations exploitent directement cette possibilité donnée par le processeur pour atteindre de meilleures performances. Tout ce domaine est actuellement essentiellement appliqué, les performances étant évaluée avec des bases de test (benchmarks). Chercher à aller vers une analyse mathématique comme proposé dans le sujet de thèse de Minh est une étape importante pour cette technologie, et, à n'en pas douter, donnera des pistes pour créer des solutions plus efficaces à long ou moyen terme.

Le sujet est ambitieux, et les différentes étapes sont naturelles et réalistes. Même s'il est toujours difficile de savoir comment un projet théorique va pouvoir avancer, il y a suffisamment de possibilités et de pistes pour être certain que des résultats intéressants seront accessibles pendant la durée d'un doctorat.

Enfin, Minh a pris contact avec moi pour un stage de master dès cet automne, et c'est lui qui a proposé de travailler sur Hyperscan. Extrêmement motivé, il a commencé à préparer son stage dès décembre (le stage a commencé en avril), quand ses cours le permettaient. Minh est très motivé, très enthousiaste et commence déjà à avoir des résultats intéressants après un peu plus d'un mois de stage. Il sera assurément un très bon doctorant; il est brillant, curieux et motivé.

NOM - Prénom : NICAUD Cyril
Fait à : Champs-sur-Marne

le 11/05/2026

Signature :

AVIS DU RESPONSABLE DU M2 OU EQUIVALENT

Nom et prénom du candidat : CHAU Dang Minh

Intitulé de la formation M2 ou équivalent : M2 mathématiques et informatique

Effectif de la formation : 12

Comment classez-vous le candidat : dans les tous premiers, dans les 10 %, dans les 25 %, dans les 50 %, dans la seconde moitié ? 1er/12

Comment évaluez-vous les capacités du candidat à accomplir une thèse ?

Le M2 mathématique & informatique est d'un niveau particulièrement élevé cette année, avec 5 étudiants internationaux recrutés sur dossier par les bourses SFRI-Bézout, qui sont d'un excellent niveau. Dang Minh Chau est l'un deux, et il est le premier du master avec plus d'un point de moyenne au-dessus du deuxième. Il a toutes les capacités pour accomplir une thèse.

NOM - Prénom du responsable de la formation : NICAUD Cyril

Fait à : Champs-sur-Marne

le 11/05/2026

Signature :

AVIS DU DIRECTEUR DE LABORATOIRE

Avis sur le candidat, l'accueil, le sujet et le financement

Nom du laboratoire :

Avis synthétique :

NOM - Prénom :

Fait à :

le __/__/__/

Signature :

